Linux 源码分析 系列之

文件系统

唐欢
htang@ncic.ac.cn
智能中心
2004.4

概要

- 静
  - UNIX系统V文件系统
  - Ext2文件系统
- 动
  - VFS文件系统
- 静↔动
  - 文件系统操作—mount root filesystem

UNIX系统V文件系统

UNIX系统V文件系统

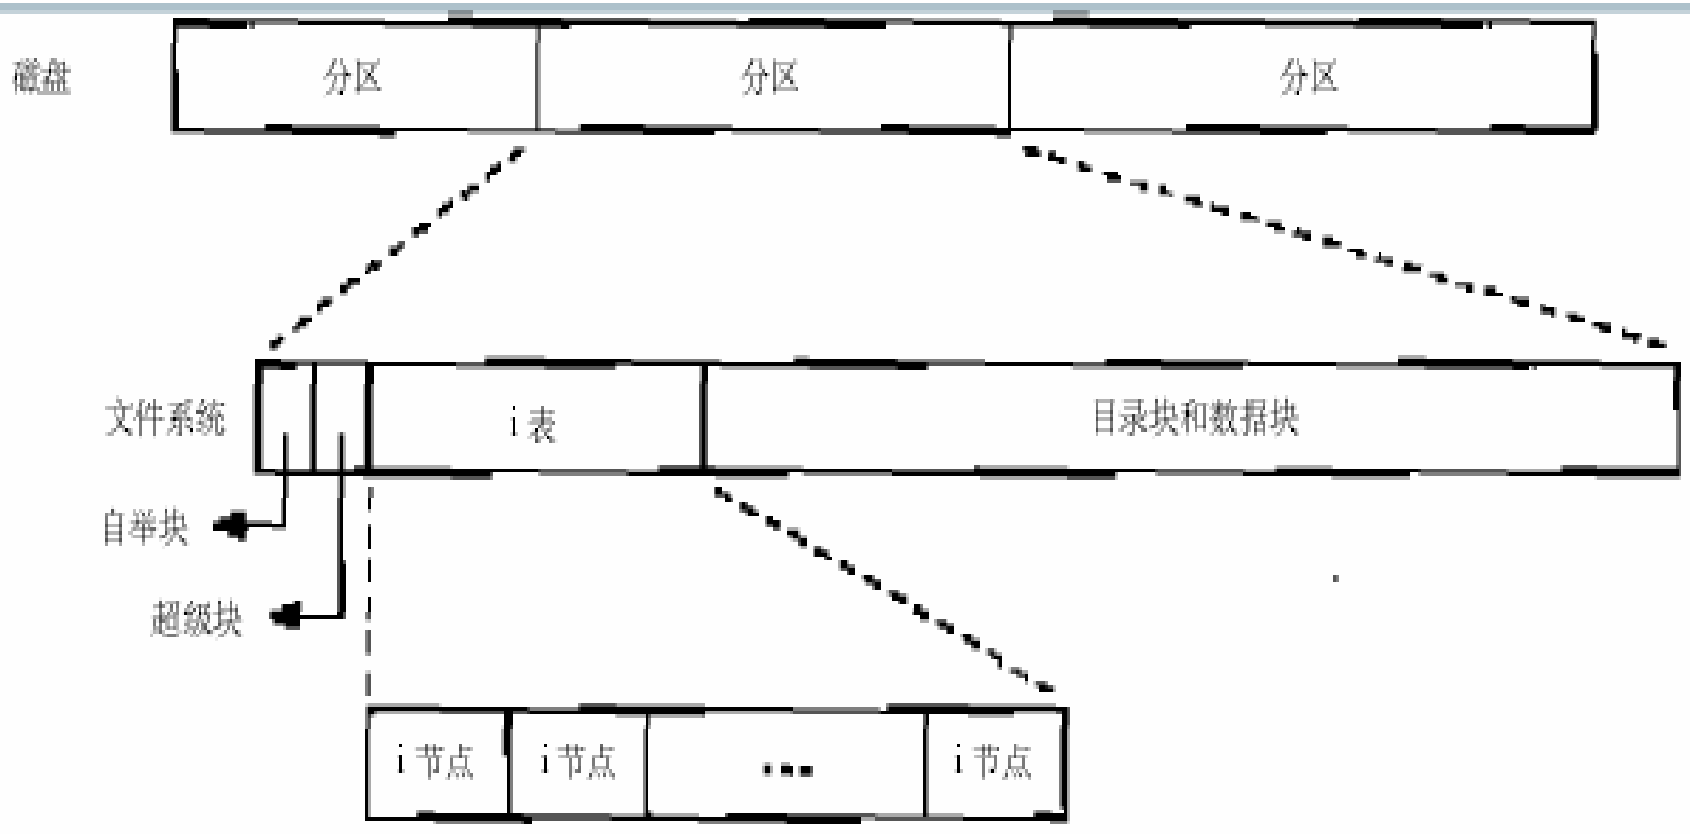

UNIX系统V文件系统
文件的信息都放在哪里？

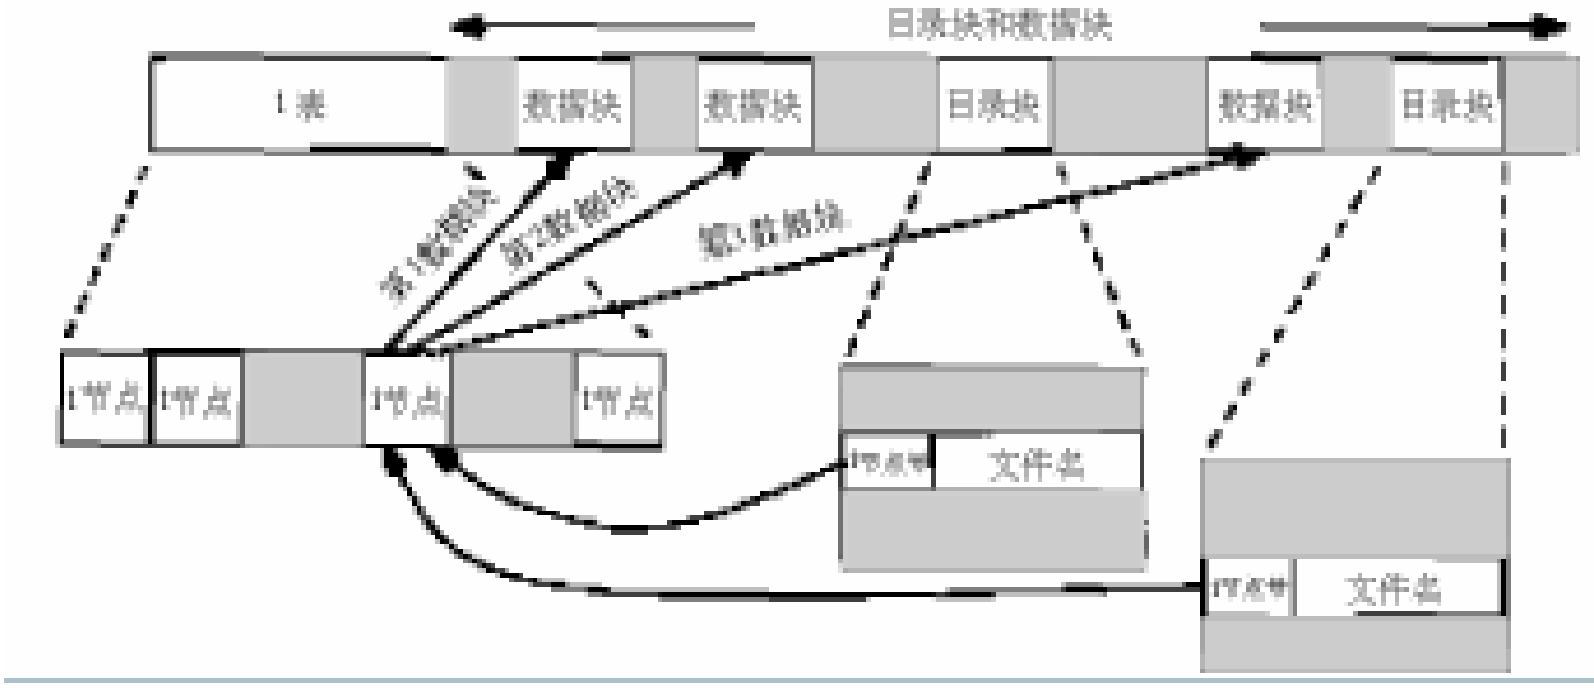

- 讨论点：文件名与inode的分离。为什么这样设计？还可以怎么样设计？

UNIX系统V文件系统
从目录项到inode

- 目录项中的inode编号指向“同一文件系统”中的inode，因此企图将目录项中inode指向其他文件系统的操作都是不允许的。例如：
- ln命令将建立一个新的目录项，指向一个现存的文件。当 /public 为NFS时：

```
dcos3:~ # ln -d /public/ /tmp/pub
ln: creating hard link `/tmp/pub' to `/public/':
Invalid cross-device link
```

- 讨论点：此举受到什么限制，能否突破？突破又有何意义？

UNIX系统V文件系统
目录怎样认识自己和爸爸

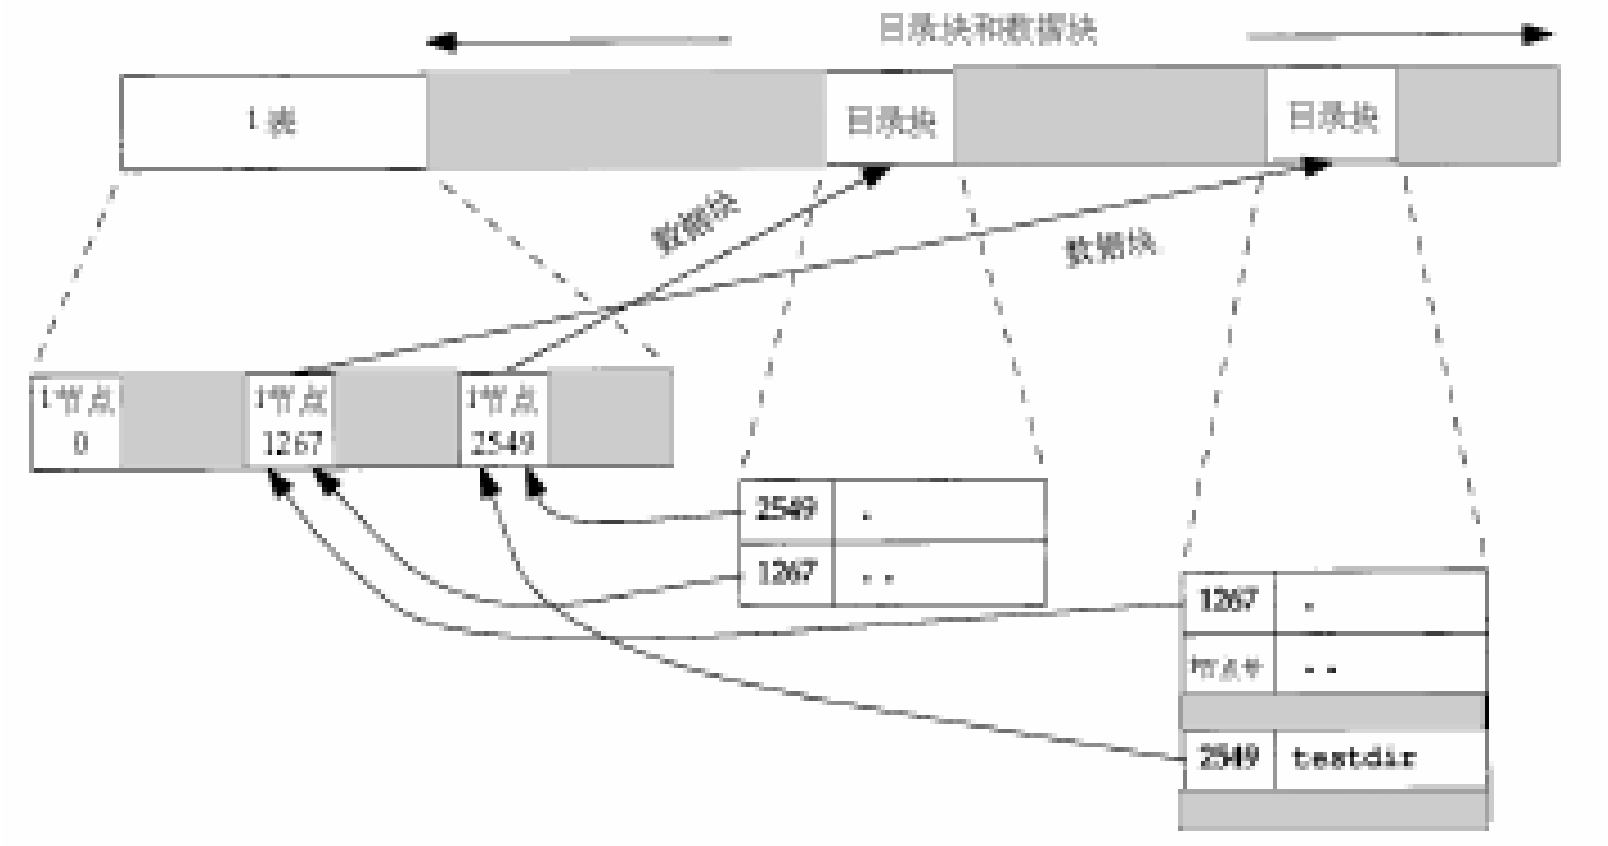

Ext2文件系统

Ext2文件系统

以block(块)为基本单位，对磁盘进行划分。block的大小在创建文件系统时可以指定。

n blocks。

保存了本组所有的inode。应[illegible]node描述文件与目录，一个文件对应一个inode，目录是一种特殊的文件。

inode 不仅记录了文件内容在外存空[illegible]间的位置，而且定义了文件的存取[illegible]修改时间、文件类型[illegible]

Block Group

将连续的block分组。为什么？

尽量将属于一个文件的block存放于一个组内，保证了访问局部性。

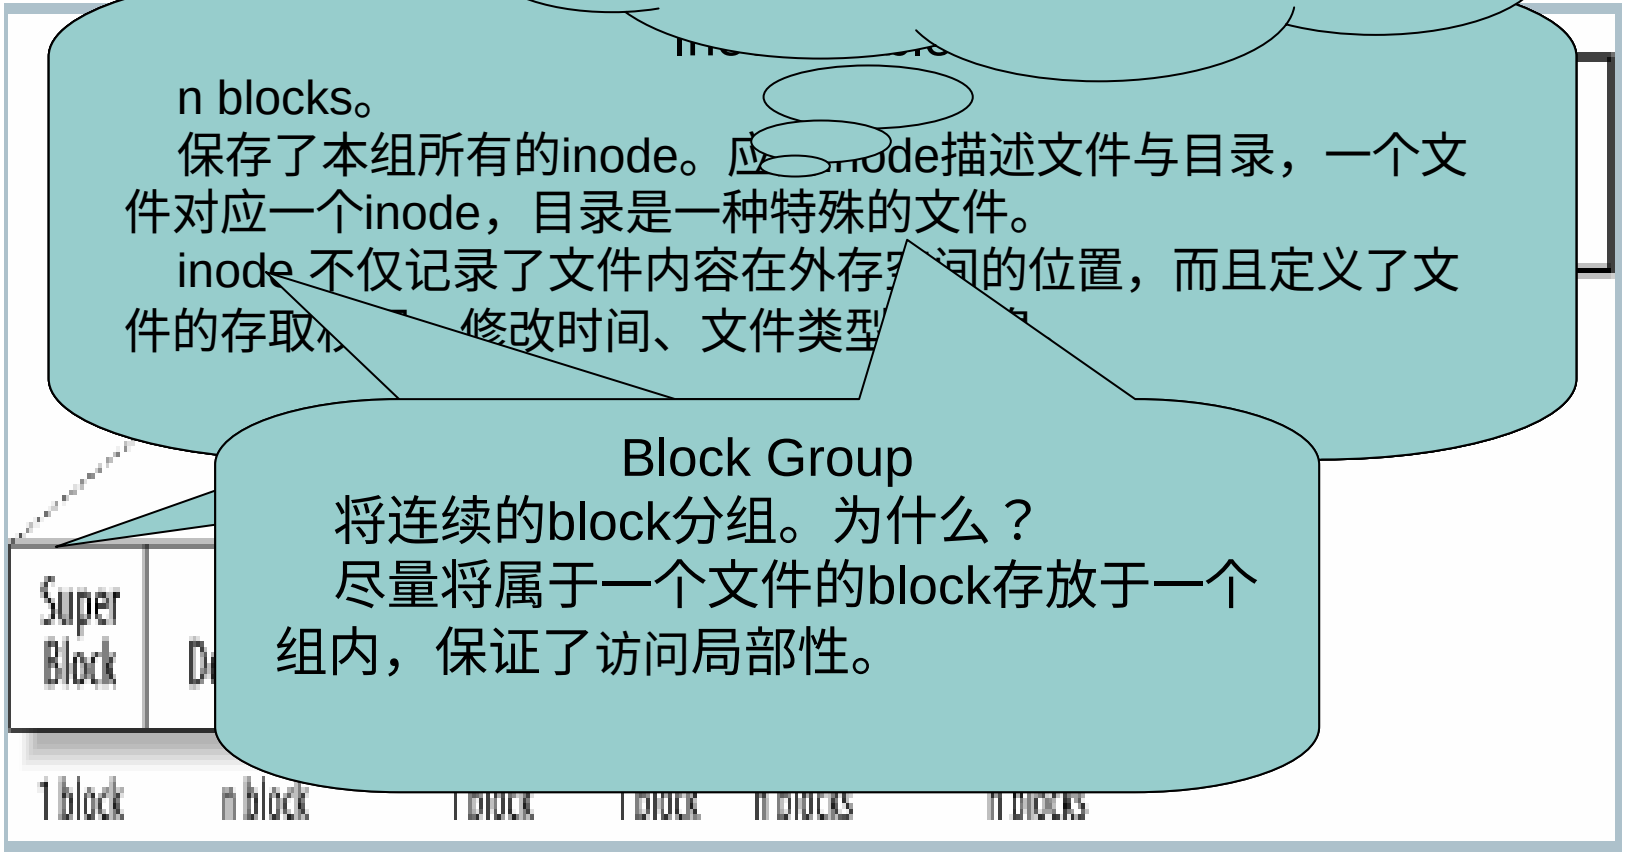

Ext2文件系统
多少个block group？

- 两个决定因素：分区大小 & block大小
- group数量 = 分区大小 / group大小
  - group大小 = block大小 X block数量
  - block数量 = block bitmap 位数(bit)
  - 且block bitmap 只占用一个block ,则：
  - block bitmap 位数 = block大小 X 8
- group大小 = block大小^2 X 8

Ext2文件系统
Super Block (/include/linux/Ext2_fs.h)

- 记录super block在磁盘上的结构
- struct ext2_super_block {
- 每一个block有多大？
- 我有多少Inode？多少block？他们中多少是free的？
- 多少个block被保留？
- 每个block group中，有多少个block？多少个inode？
- 第一个Data block在哪里？
- 我何时mount？mount了几次？最多可以mount几次？
- 上一次write操作在何时？上一次check操作在何时？
- ……
- }

Ext2文件系统
Group Discriptor (/include/linux/Ext2_fs.h)

```
struct ext2_group_desc
{
        __u32   bg_block_bitmap;  /* Blocks bitmap block */
        __u32   bg_inode_bitmap;  /* Inodes bitmap block */
        __u32   bg_inode_table;     /* Inodes table block */
        __u16   bg_free_blocks_count;   /* Free blocks count */
        __u16   bg_free_inodes_count;  /* Free inodes count */
        __u16   bg_used_dirs_count;     /* Directories count */
        __u16   bg_pad;
        __u32   bg_reserved[3];
}
```

Ext2文件系统
Inode —基本“构件”

```
struct ext2_inode {
        __u16   i_mode;
        __u32   i_size;
        __u32   i_atime;
        __u32   i_ctime;
        __u32   i_mtime;
        __u32   i_dtime;
        __u16   i_links_count;
        __u32   i_blocks;
        __u32   i_block[EXT2_N
        __u32   i_file_acl;
        __u32   i_dir_acl;      /* Directory ACL */
}
```

i_mode

atime ctime mtime

atime-- 文件数据的最后访问时间

mtime-- 文件数据的最后修改时间

i_block

指向inode所描述的Data block的指针。其中：EXT2_N_BLOCKS = 15

acl

Access Control List

Ext2文件系统
i_mode 表示的多种文件类型

File_type	Description
0	Unknown
1	Regular file
2	Directory
3	Character device
4	Block device
5	Named pipe
6	Socket
7	Symbolic link

Ext2文件
EXT2 目

- (/include/li

inode r

Ex.

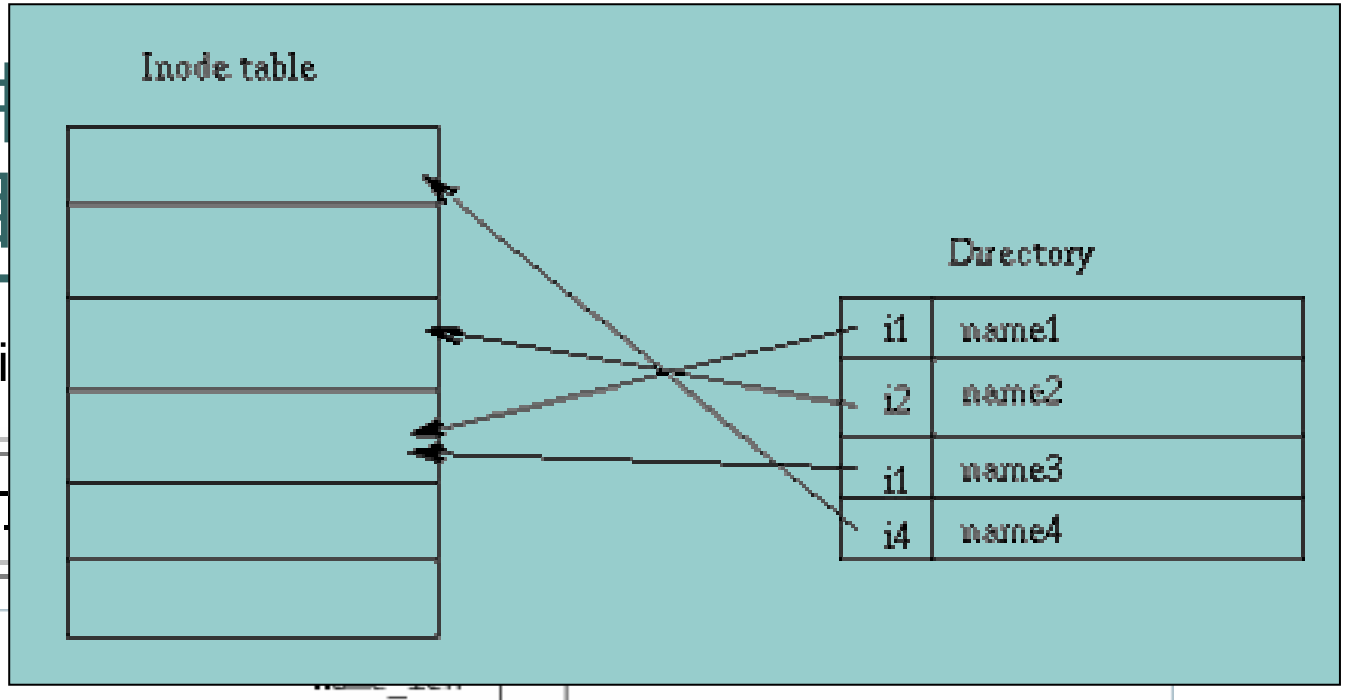

	inode	rec_len			name							
0	21	12	1	2	.	\0	\0	\0				
12	22	12	2	2	.	.	\0	\0				
24	53	16	5	2	h	o	m	e	1	\0	\0	\0
40	67	28	3	2	u	s	r	\0				
52	0	16	7	1	o	l	d	f	i	l	e	\0
68	34	12	4	2	s	b	i	n				

```
__u32   i_block[EXT2_N_BLOCKS];  /* Pointers to blocks */

#define EXT2_NDIR_BLOCKS  12
#define EXT2_IND_BLOCK      EXT2_NDIR_BLOCKS       //12
#define EXT2_DIND_BLOCK     (EXT2_IND_BLOCK + 1)   //13
#define EXT2_TIND_BLOCK     (EXT2_DIND_BLOCK + 1) //14
#define EXT2_N_BLOCKS       (EXT2_TIND_BLOCK + 1) //15
```

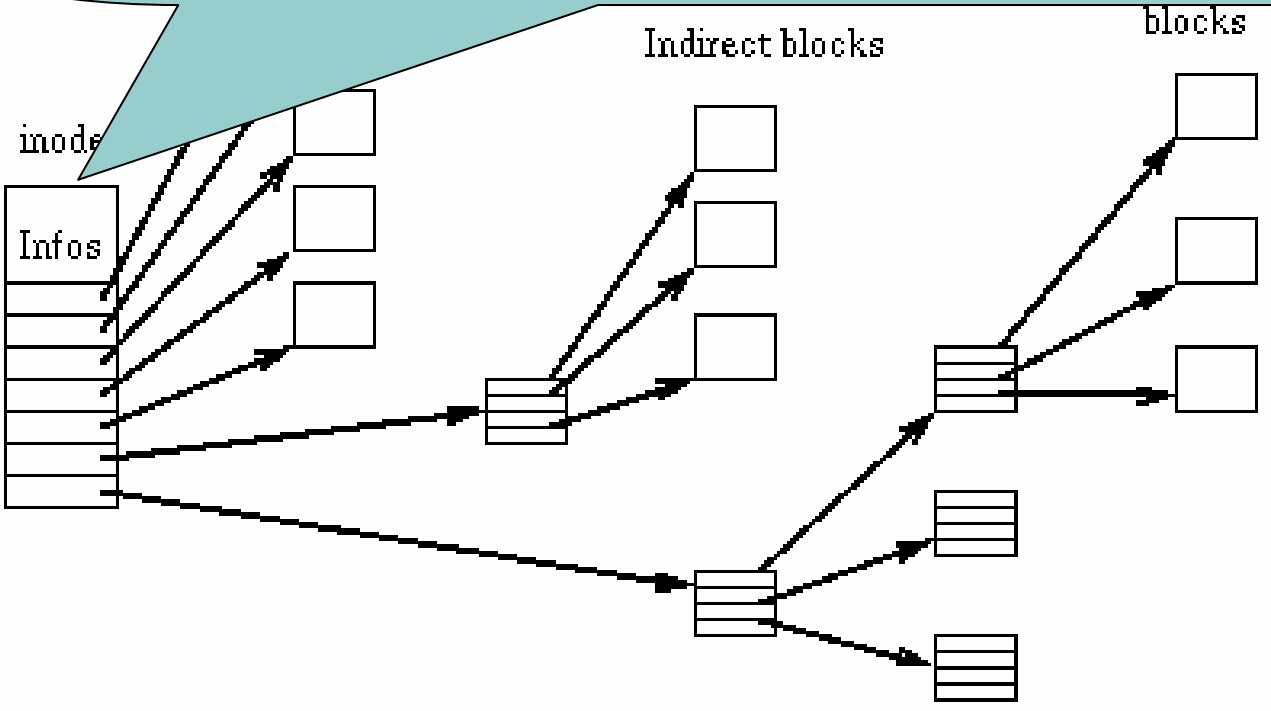

Ext2文件系统
符号连接 Symbolic link

- 符号连接记录了目标的路径。如果这一“记录”的长度小于 60 字符, 将被写入 i_block数组中。否则，当其长度大于60时，将占用一个block来存储。
- 60 从哪里来？

```
__u32  i_block[EXT2_N_BLOCKS];
```

↓ 4 Byte　　↓ 15

i_block占用空间 = 15 X 4 = 60 Byte

Ext2文件系统
谁不需要block？

- 空文件
- 符号连接(当目标路径长度 < 60)
- 设备文件(块设备、字符设备)
- Socket
- Named pipe
- ？

VFS文件系统

VFS文件系统

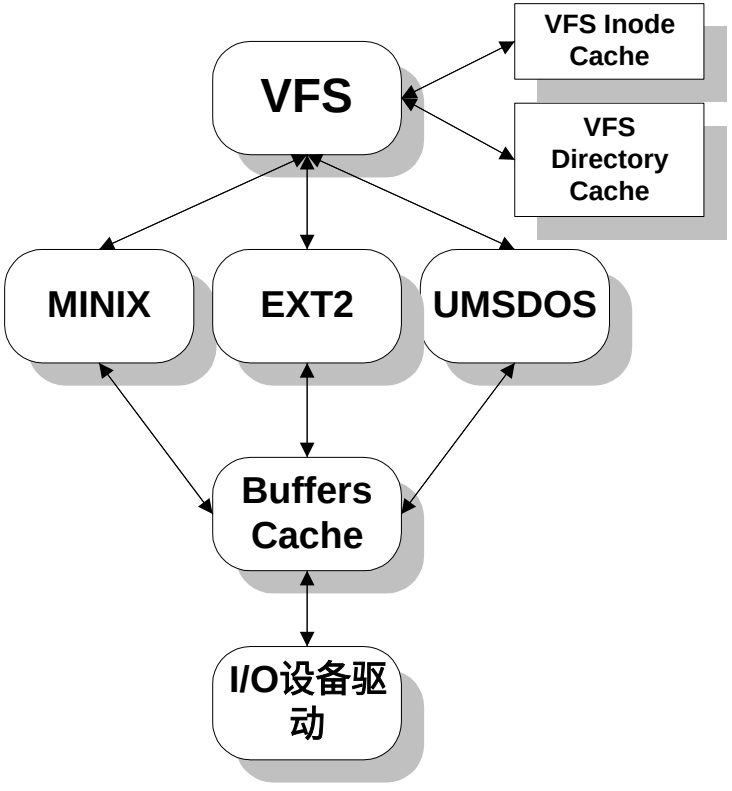

- VFS是物理文件系统与服务之间的一个接口层。
- VFS对Linux的每个文件系统的所有细节进行抽象。
- VFS只存在于内存中，不存在于任何外存空间。
- VFS在系统启动时建立，在系统关闭时消亡。

VFS文件系统
MM ➔ VFS

物理内存可动态地映射成进程的虚拟内存

↓

外部文件系统可动态地映射成VFS

外部文件系统中的文件可动态地映射成VFS中的文件。

说得更精确些，就是外部文件系统中某一文件的某一物理块可以动态映射成VFS中该文件的页块。

VFS文件系统
功用

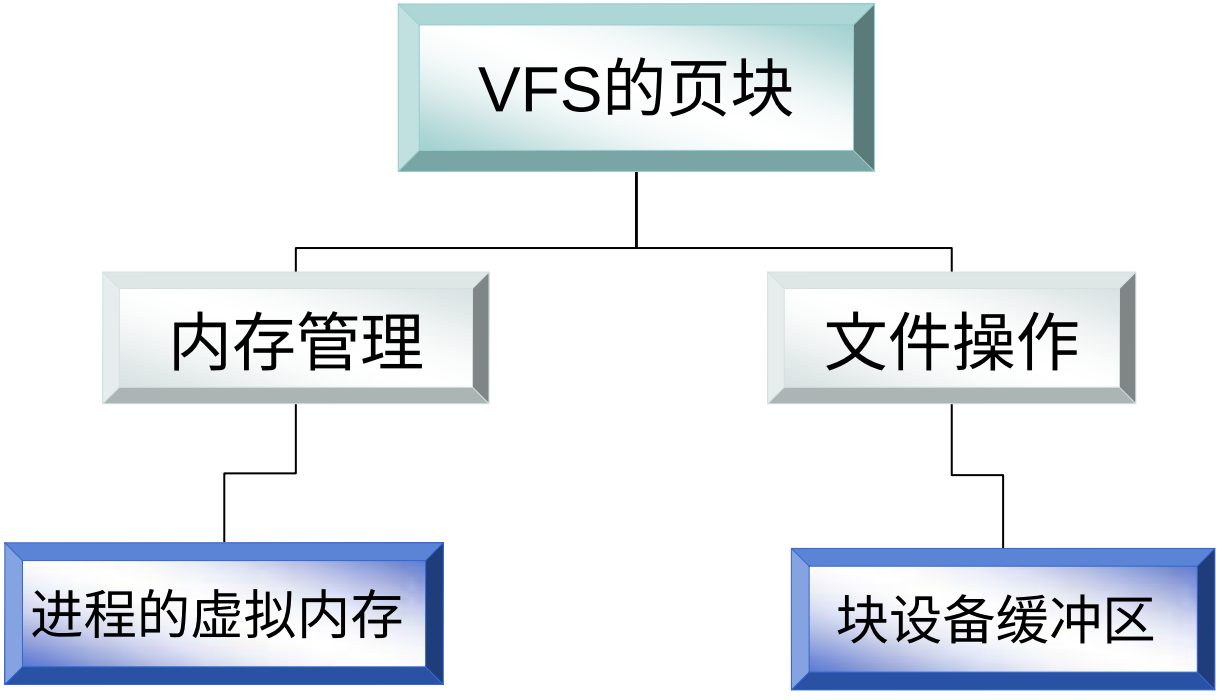

VFS文件系统
为文件操作提供的函数

- 管理缓冲区　(buffer. c)
- 响应系统调用fcntl() 和ioctl()　(fcntl.c & ioctl.c)
- 将管道和文件输入/输出映射到索引节点和缓冲区(fifo.c, pipe.c)
- 锁定和不锁定文件和记录(locks.c)
- 映射名字到索引节点(namei.c, open.c)
- 实现select( )函数(select . c)
- 提供各种信息(stat.c)
- 挂接和卸载文件系统(super.c)
- 调用可执行代码和转存核心(exec.c)
- 装入各种二进制格式(bin_fmt*.c)

VFS文件系统
主要模块

三个进程打开

inode object
保存某一文件的基本信息。
For disk-based filesystems, this object usually corresponds to a *file control block* stored on disk.

bject
相关的信息。
, this object
lesystem
k.

dentry object
保存目录项和其相应文件间链接的信息。
不同的文件系统以不同方式存储这种信息。
ext2:目录是特殊的文件
FAT(File Allocation Table)：目录不是文件，使用FAT记录文件在目录树中的位置。

object
开文件的交互信息。这
程访问文件时存储与内

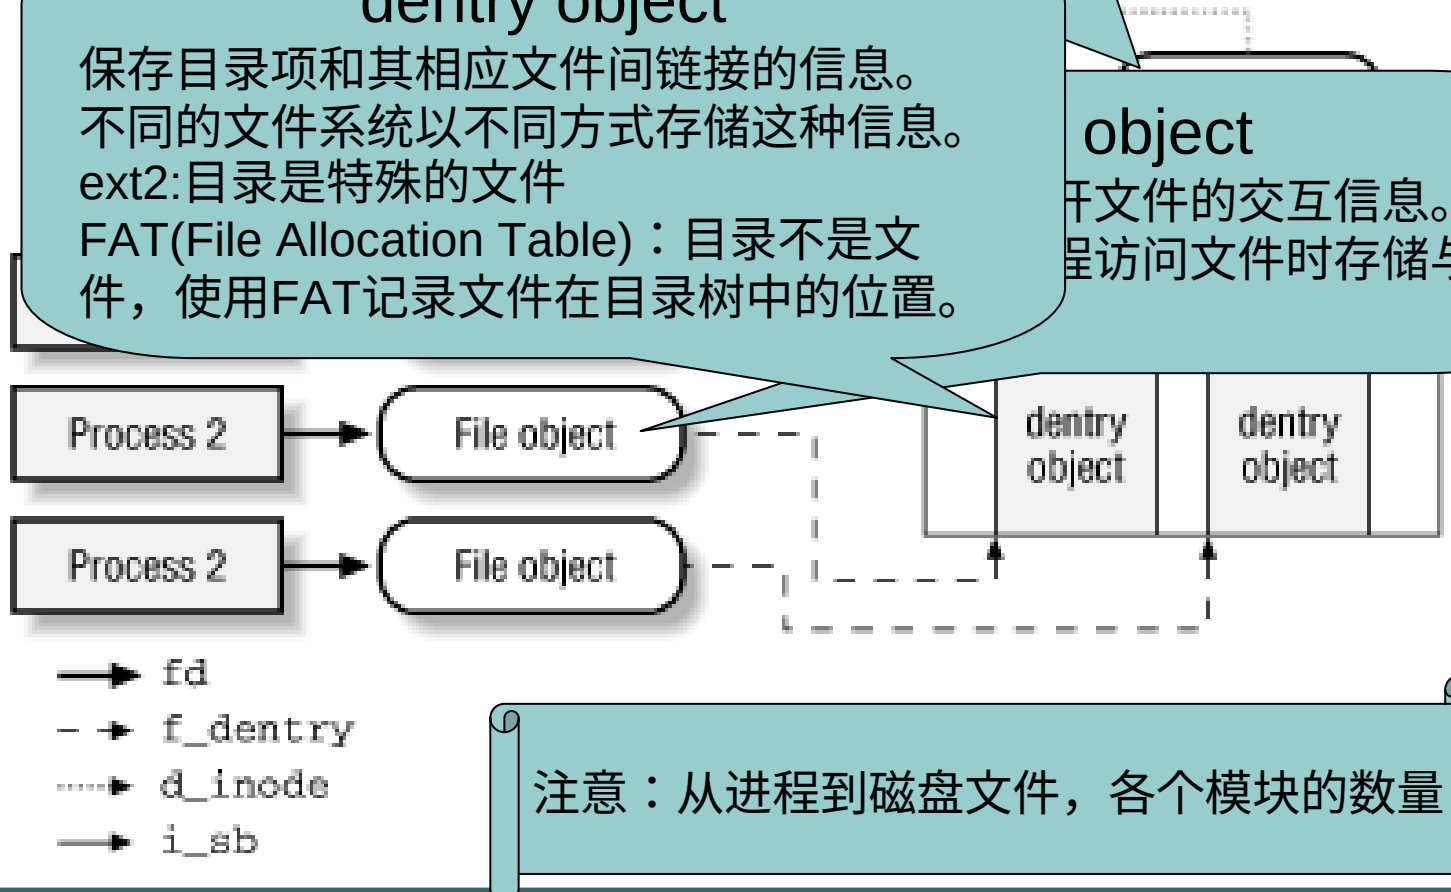

注意：从进程到磁盘文件，各个模块的数量

编外—源码中面向对象的痕迹

- VFS的OO特性
  - VFS是对所有具体文件系统的抽象。包括系统的结构与相关的操作。
- VFS的OO实现

Object XXX
数据成员
成员函数

VFS `Object`

struct XXX{
struct XXX_operations * X_op;
}

struct XXX_operations{
(*function_A)
(*function_B)
}

VFS文件系统
super block Object (/include/linux/fs.h)

super_block Object

```
struct super_block {
    struct  super_operations *s_op;
        ....
}
```

```
struct super_operations {
   void (*read_inode) (struct inode *);
   void (*write_inode) (struct inode *, int);
   void (*delete_inode) (struct inode *);
   ....
}
```

为保证文件系统性能，设备的super block必须驻留内存，整个VFS的super block实现这样的内存空间。

super block记录文件系统的具有共性的信息(如:文件锁、修改标志)，还连接着具体文件系统的特有信息。同时，拥有着作用于这些信息成员之上的操作。

VFS文件系统
super block 数据成员(/include/linux/fs.h)

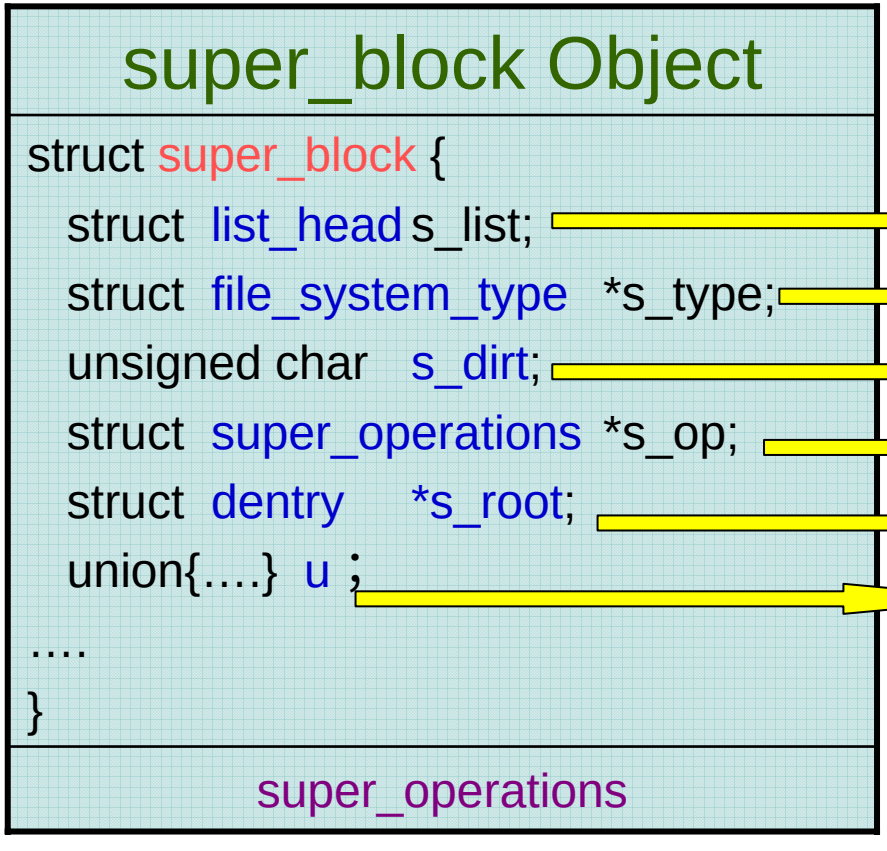

super block部分数据成员：

- 连接多个super block的双向链表
- 文件系统类型
- 已修改(脏)的标志
- super block 操作集
- 挂载的dentry object 对象
- 特定文件系统的super block信息。

VFS文件系统
super block 数据成员 super_block.s_list

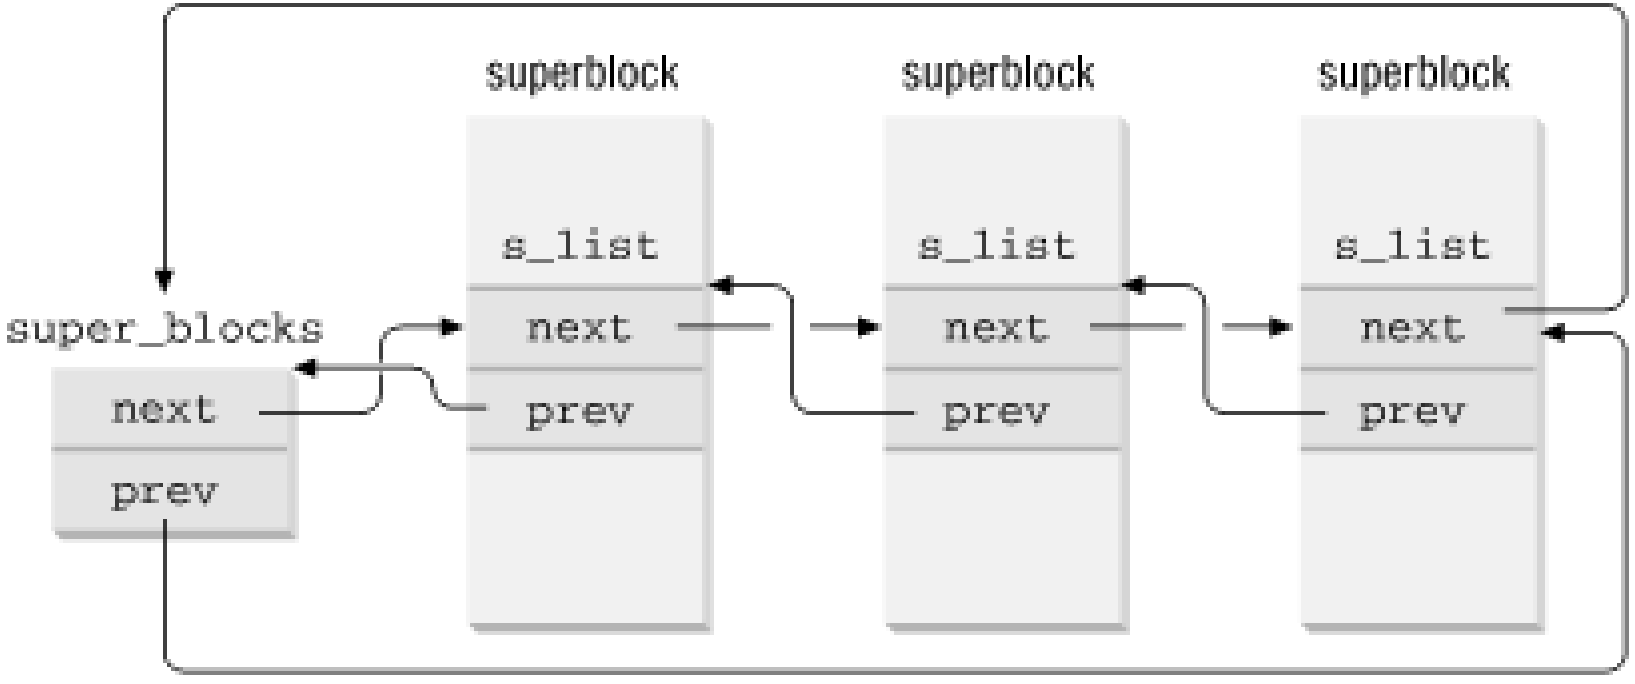

讨论点：还有很多的这样的链表，连在一起组成一张网，有谁清楚知道网的结构？有什么共性？

VFS文件系统
super block 数据成员 super_block.u

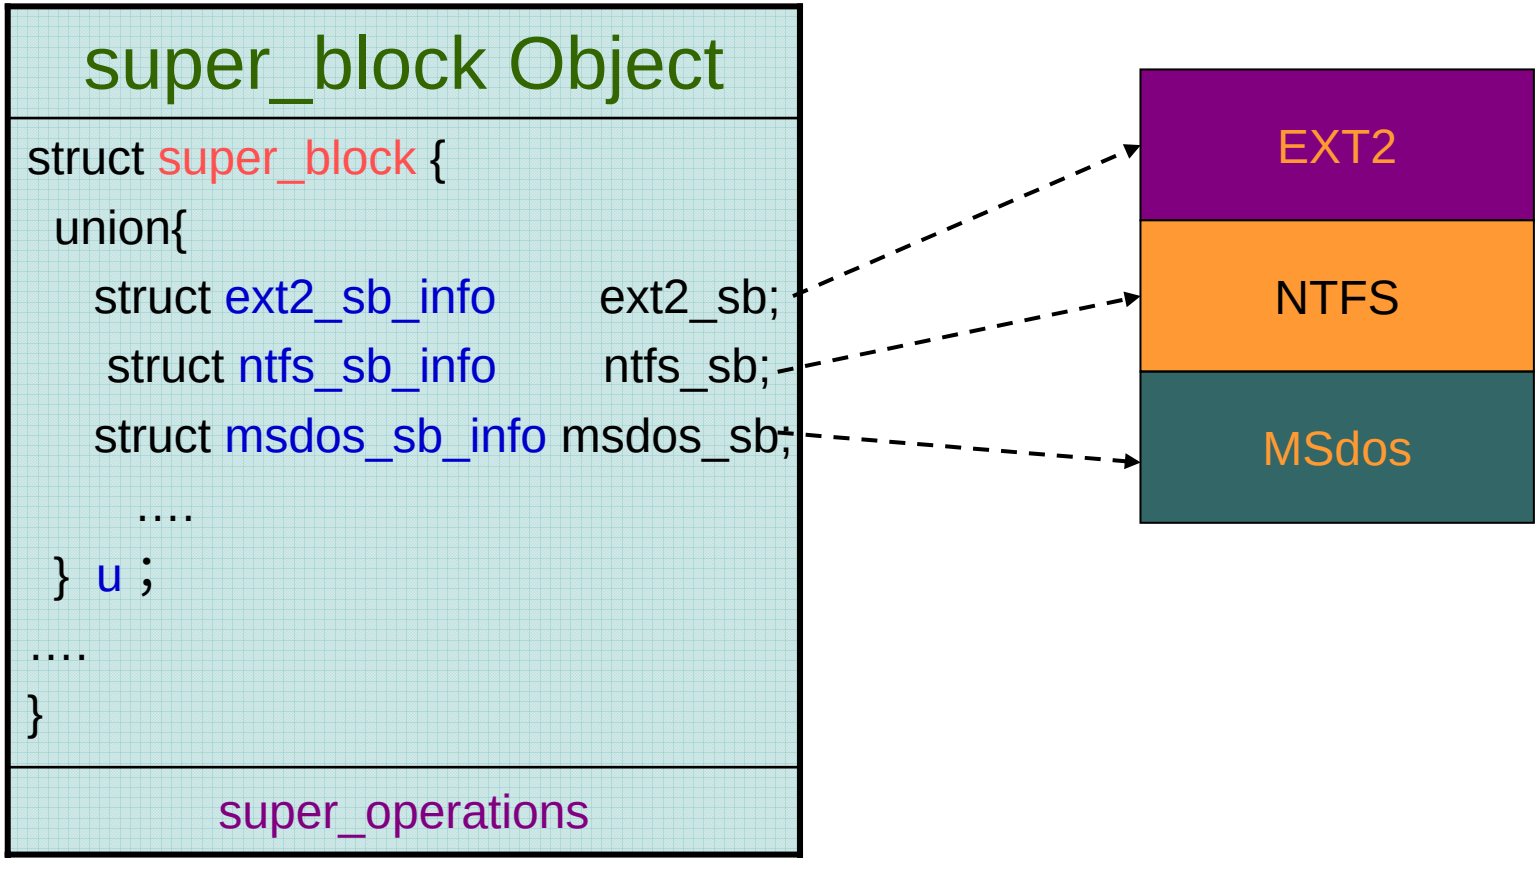

VFS文件系统
super block 函数成员(/include/linux/fs.h)

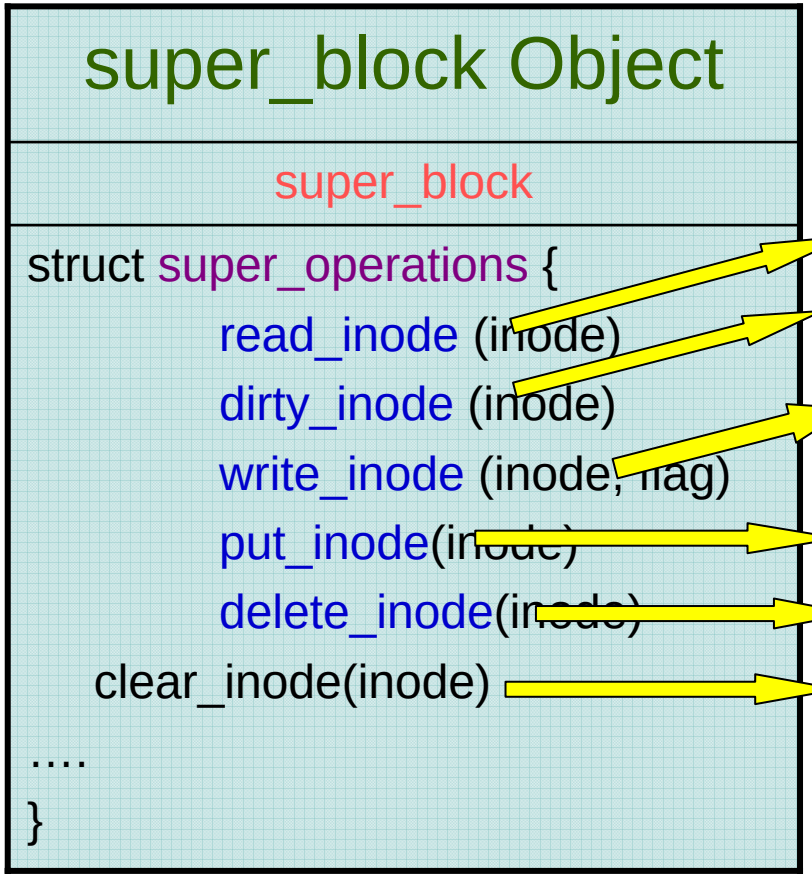

- superblock函数成员功能：
  - 从磁盘读取信息填写inode(内存)
  - 当dirty标志被置位时执行(EXT3)
  - 更新inode内容，flag决定是否同步磁盘
  - 释放与inode关联，不释放内存
  - 删除inode(磁盘操作)
  - 同put_inode,同时释放内存

VFS文件系统
inode Object (/include/linux/fs.h)

inode Object

```
struct inode {
    struct inode_operations  *i_op;
        ....
}
```

```
struct inode_operations {
    int (*create)
    int (*link)
    int (*mkdir)
   ....
}
```

文件系统对文件和目录的控制全都由inode实现。inode是Linux管理文件系统的最基本的单位，也是任何文件系统连接任何子目录、任何文件的桥梁。

VFS的inode对数据与操作的实现与super block相同。

VFS文件系统
inode 数据成员 inode.u

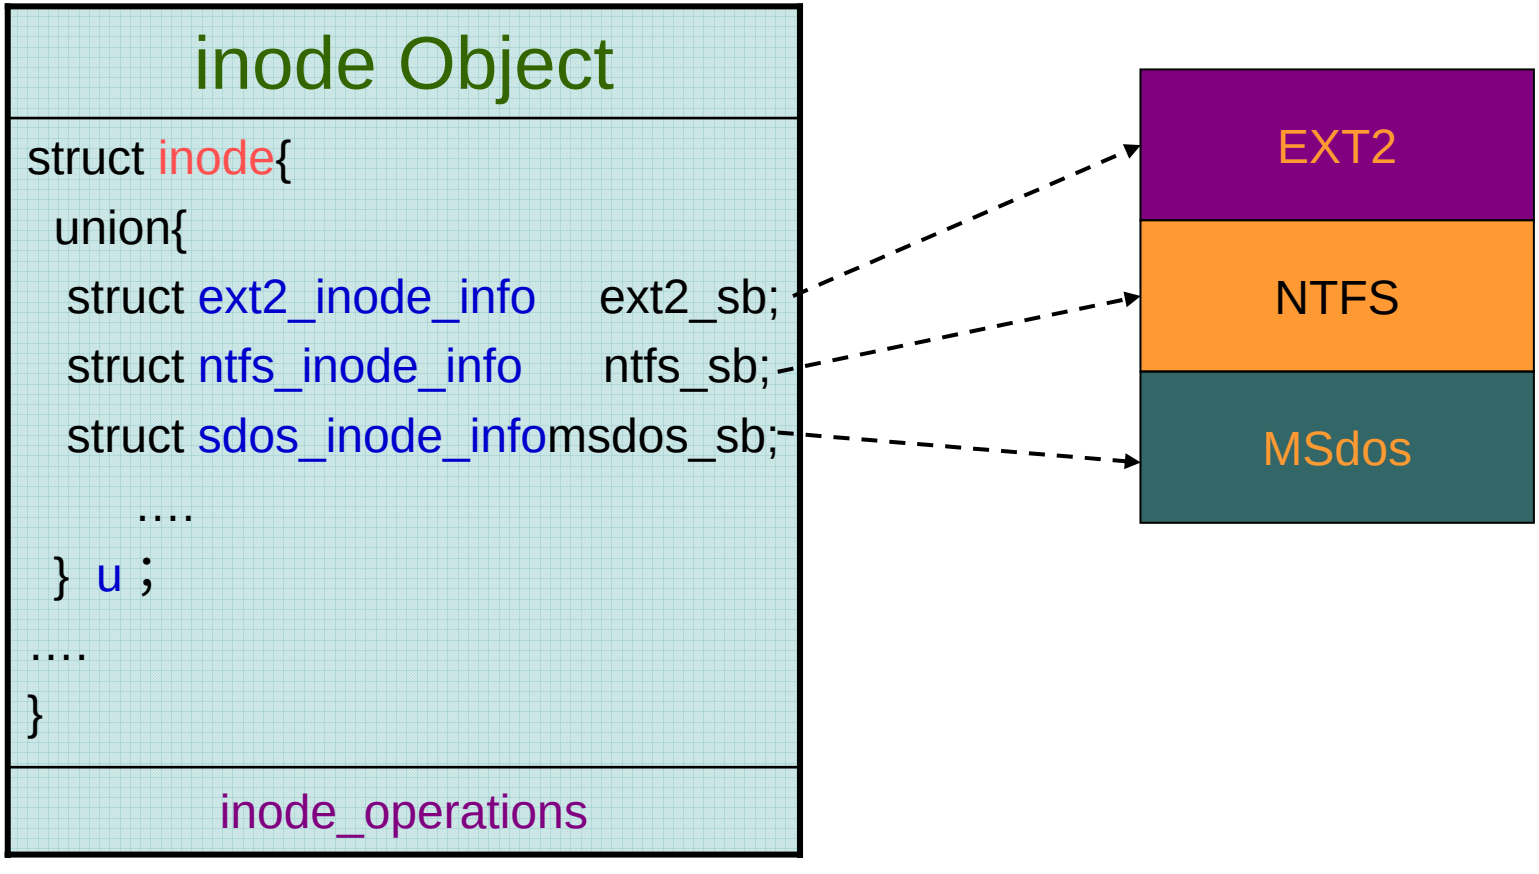

VFS文件系统
inode 函数成员(/include/linux/fs.h)

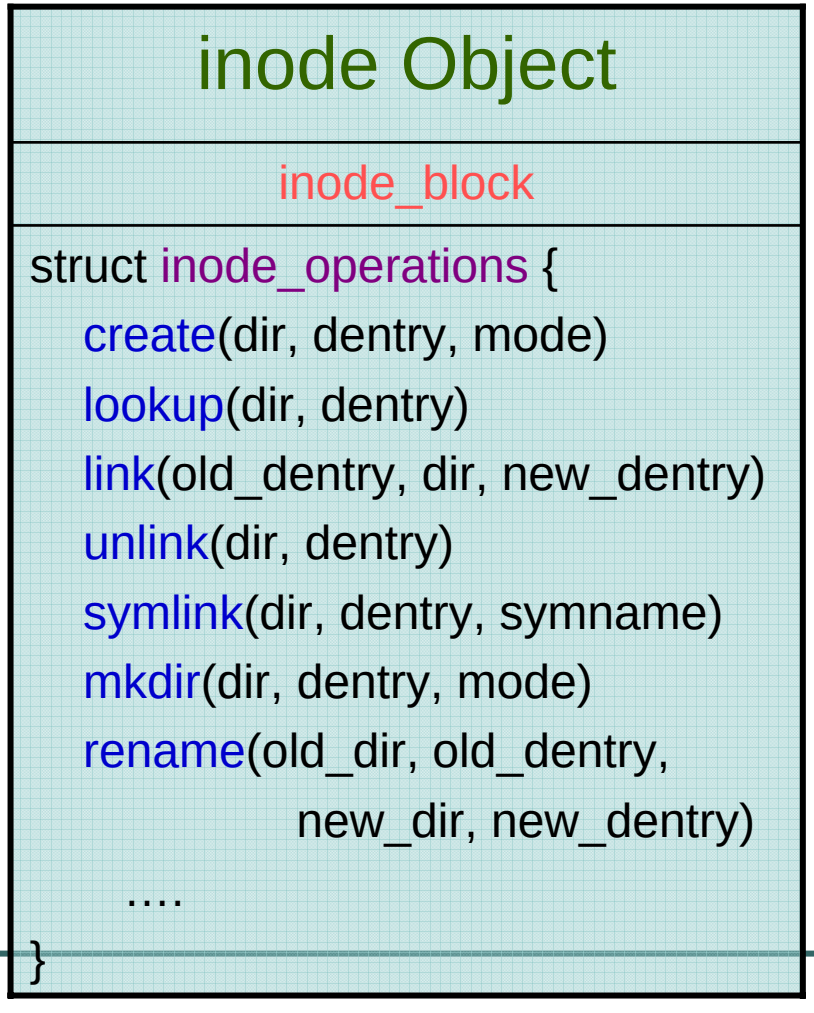

VFS文件系统
file Object (/include/linux/fs.h)

file Object

```
struct file {
    struct file_operations      *f_op;
        ....

}
```

```
struct file_operations {
    loff_t (*llseek)
    ssize_t (*read)
    ssize_t (*write)
   ....
}
```

- file Object 描述了进程与其打开文件间的交互过程。
- file Object在进程打开一个文件时创生。

VFS文件系统
file 数据成员

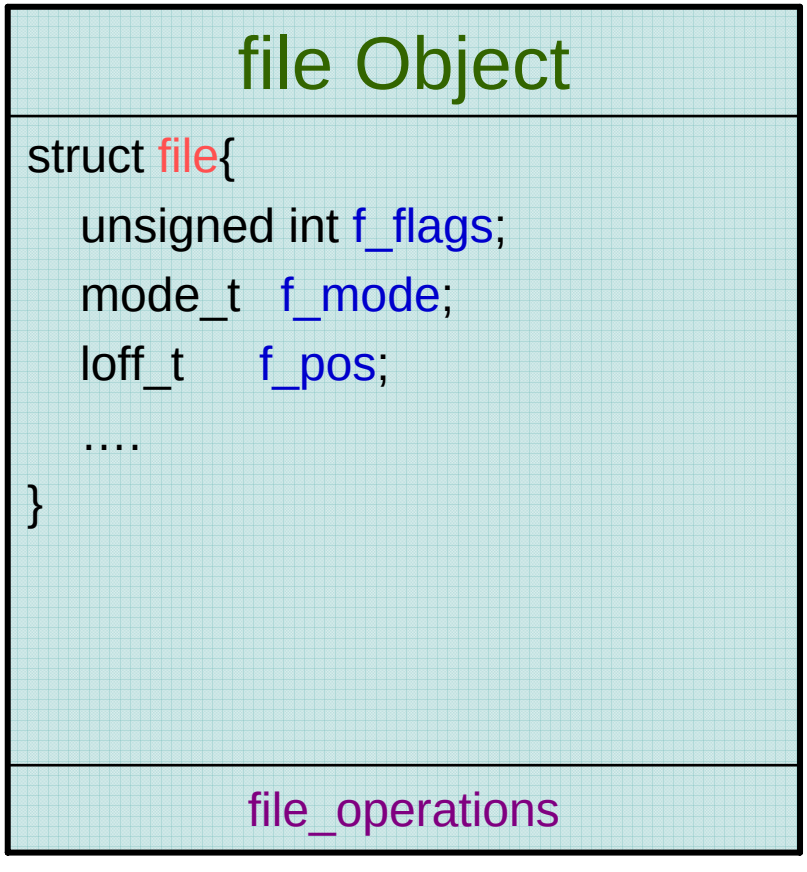

- file 数据成员并不像super block和inode一样，在磁盘上有着对应的结构。
- file结构中没有dirty标志。

VFS文件系统
file 函数成员

file Object
file_block

struct file_operations {
llseek(file, offset, origin)
read(file,buf, count, offset)
write(file, buf, count, offset)
readdir(dir, dirent, filldir)
poll(file, poll_table)
open(inode, file)
flush(file) ….
}

- 每个文件系统都有自己对文件的操作的具体实现。当内核将磁盘上的inode读入内存当中时，对其操作的具体函数地址保存在file_operations结构中，同时file_operations结构的地址保存在struct inode中的i_fop成员变量中。

VFS文件系统
dentry Object (/include/linux/Dcache.h)

dentry Object

```
struct dentry {
    struct dentry * d_parent;
    struct list_head d_hash;
    struct list_head d_lru;
    struct list_head d_child;
    struct list_head d_subdirs;
        ....
}
```

```
struct dentry_operations {
....
}
```

- 当目录被VFS读入内存中后，便被看作一个dentry对象保存到dentry结构中。
- 对一个进程所要寻找的一个路径来说，内核为其每一级目录创建一个dentry对象。如：

对于 /tmp/test

创建 / tmp test 三个dentry

VFS文件系统
dentry Object数据成员

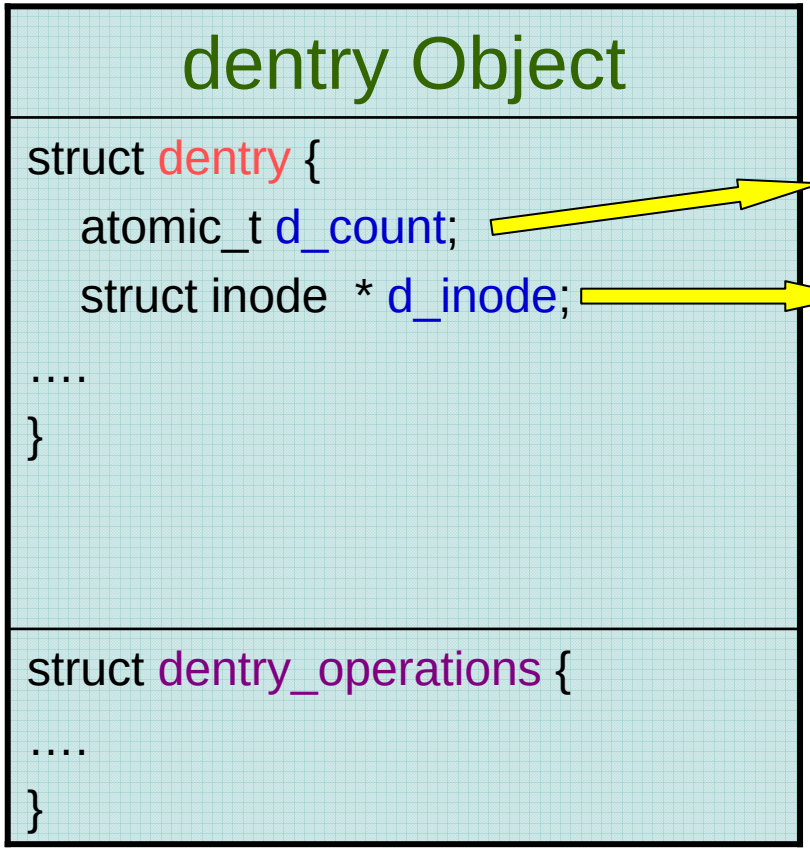

- dentry对象计数
- 与文件名对应的inode

VFS文件系统
dentry Object的状态

	状态描述	d_count	d_inode	内存情况
free	没有可用信息	/	/	由调度程序掌管
Unused	dentry当前不被使用	0	指向相应inode	随时可能被回收
In use	内核正在使用	>0	指向相应inode	不会被回收
Negative	相应inode不存在	/	NULL	/

VFS文件系统
dentry & inode

- 为什么同样描述文件，要使用dentry与inode两套结构？

  因为他们各自对文件的描述角度不同。

  一个文件可能有好几个文件名，而通过不同的文件名来访问同一文件时权限可能是不同的。

  dentry结构代表了逻辑意义上的文件，记录着其逻辑意义上的属性。

  inode结构代表物理意义上的的文件，记录物理上的属性。

  dentry与inode之间是一种“多对一”的关系

VFS文件系统
进程与文件的关联

```
struct task_struct {
        /* open file information */
        struct files_struct *files;
}
```

```
struct files_struct {

        struct file ** fd;

}
```

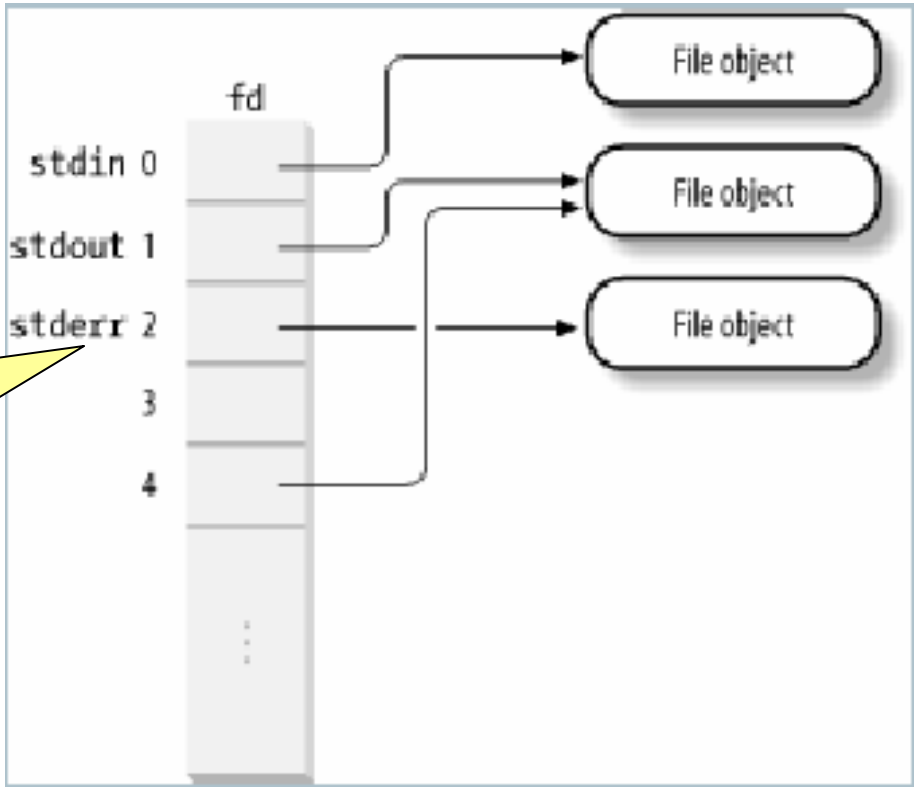

VFS文件系统
进程与文件的关联-续

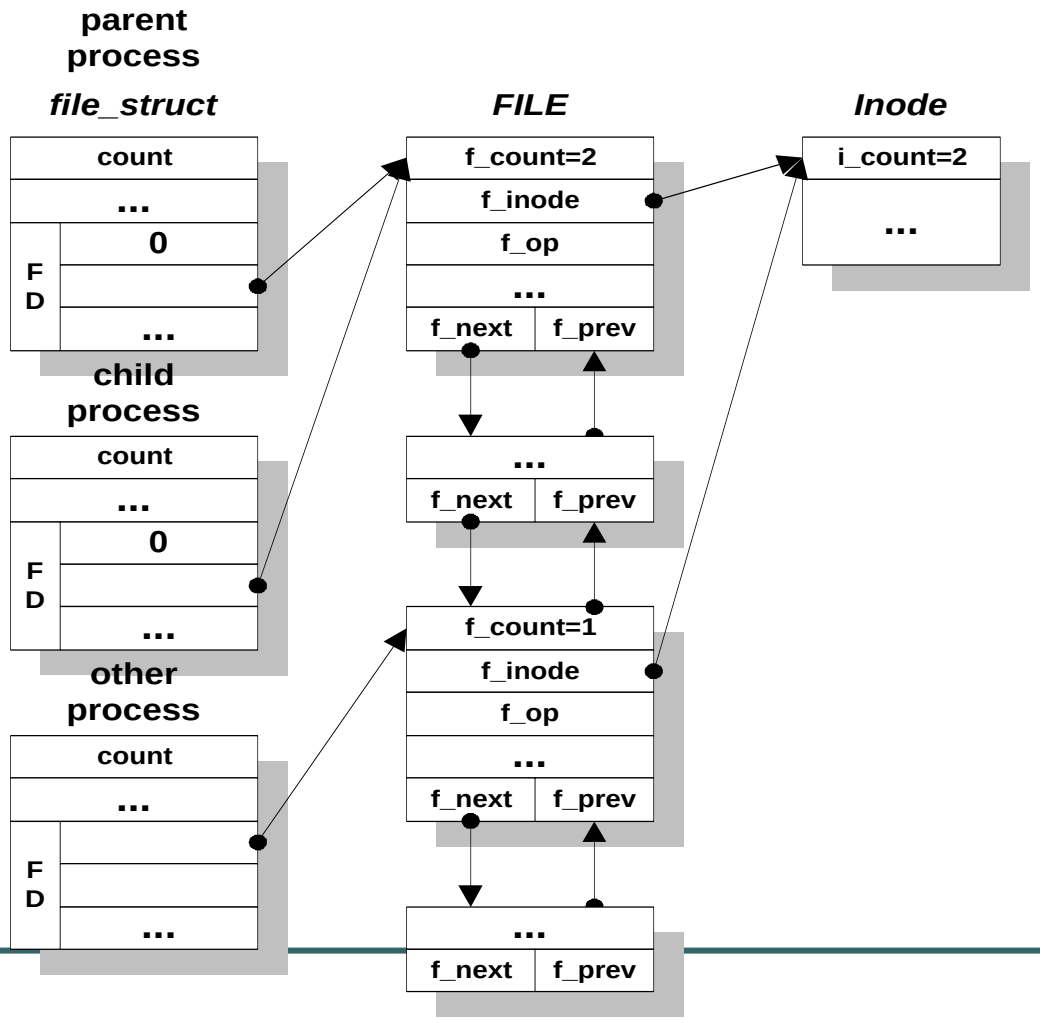

VFS文件系统
全局逻辑结构

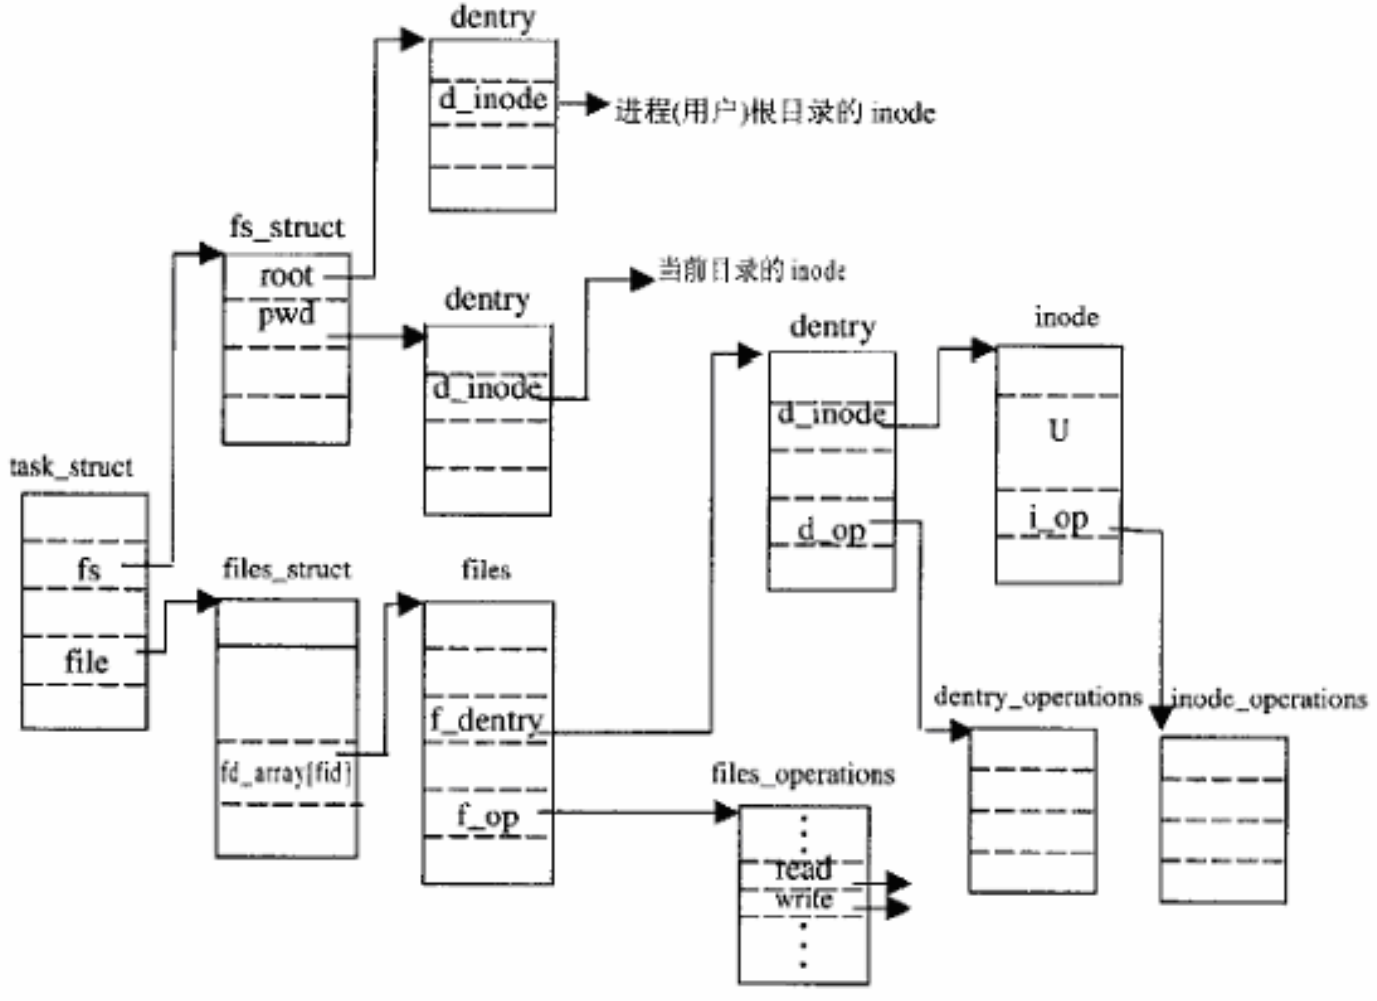

文件系统操作
mount root filesystem

文件系统操作
mount root filesystem

- 第一阶段
  - 内核挂载一个特殊的 rootfs 文件系统，它仅是一个空的目录，将作为最初的挂载点
- 第二阶段
  - 内核将真正的root挂载到此空目录上

文件系统操作mount root filesystem 第一阶段-1

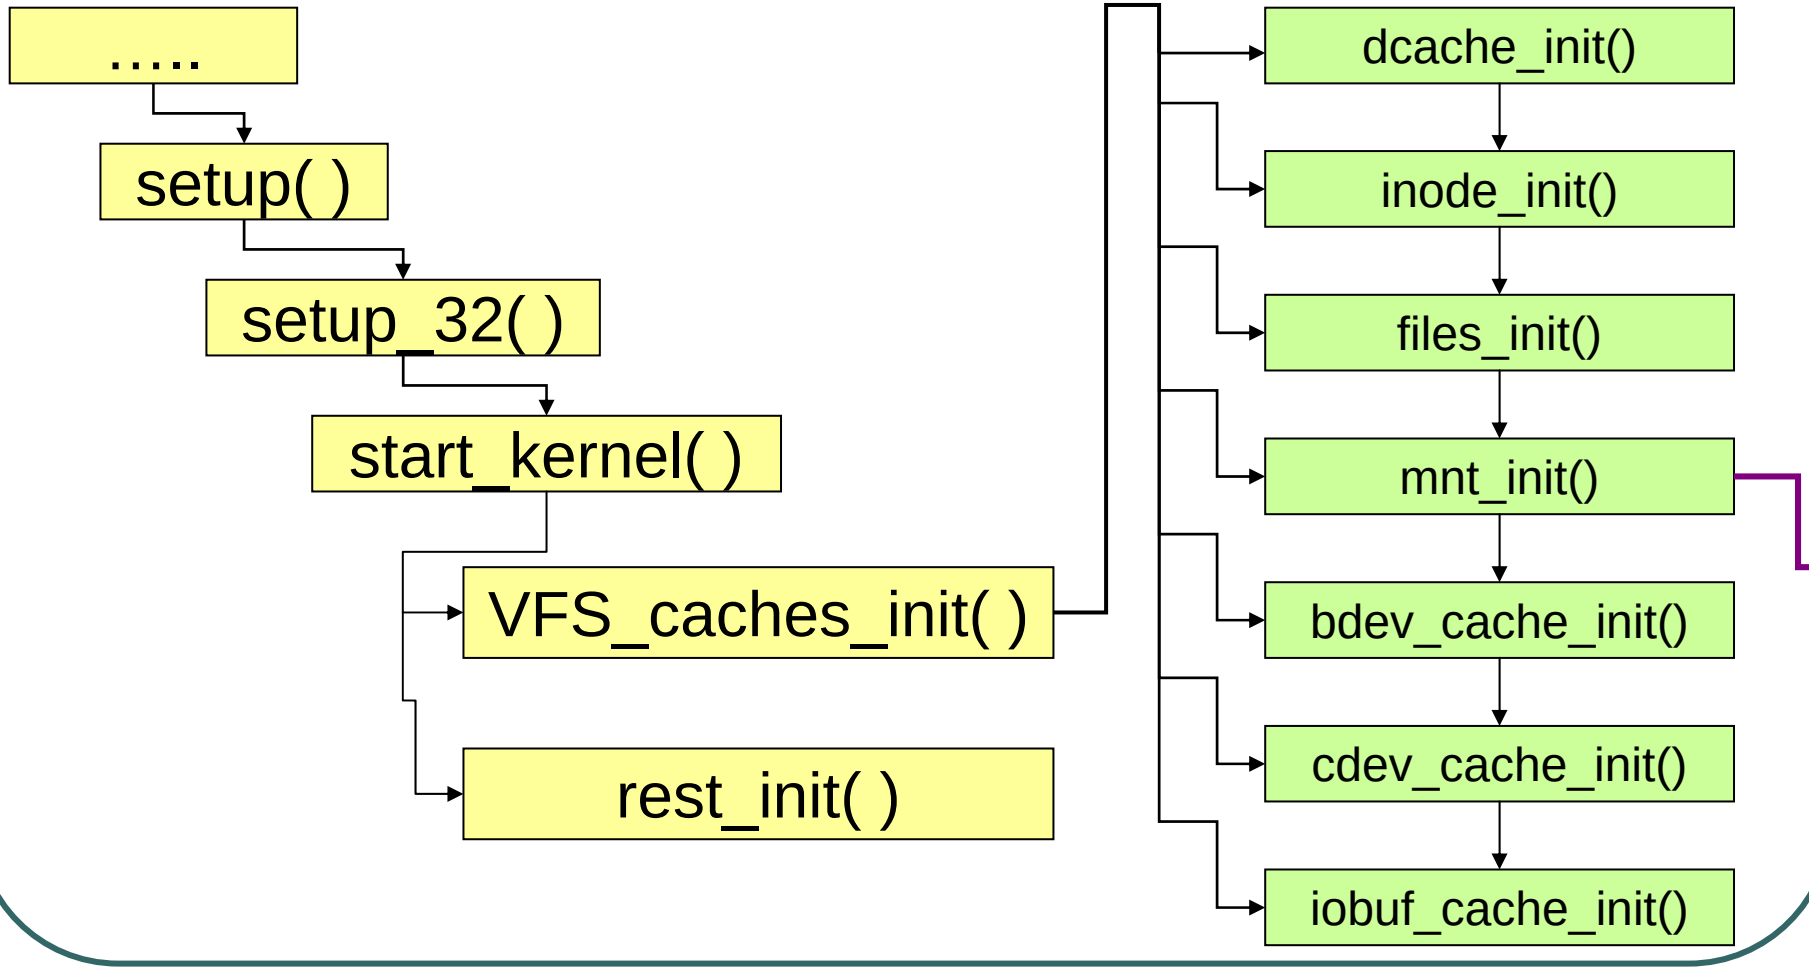

文件系统操作mount root filesystem 第一阶段-2

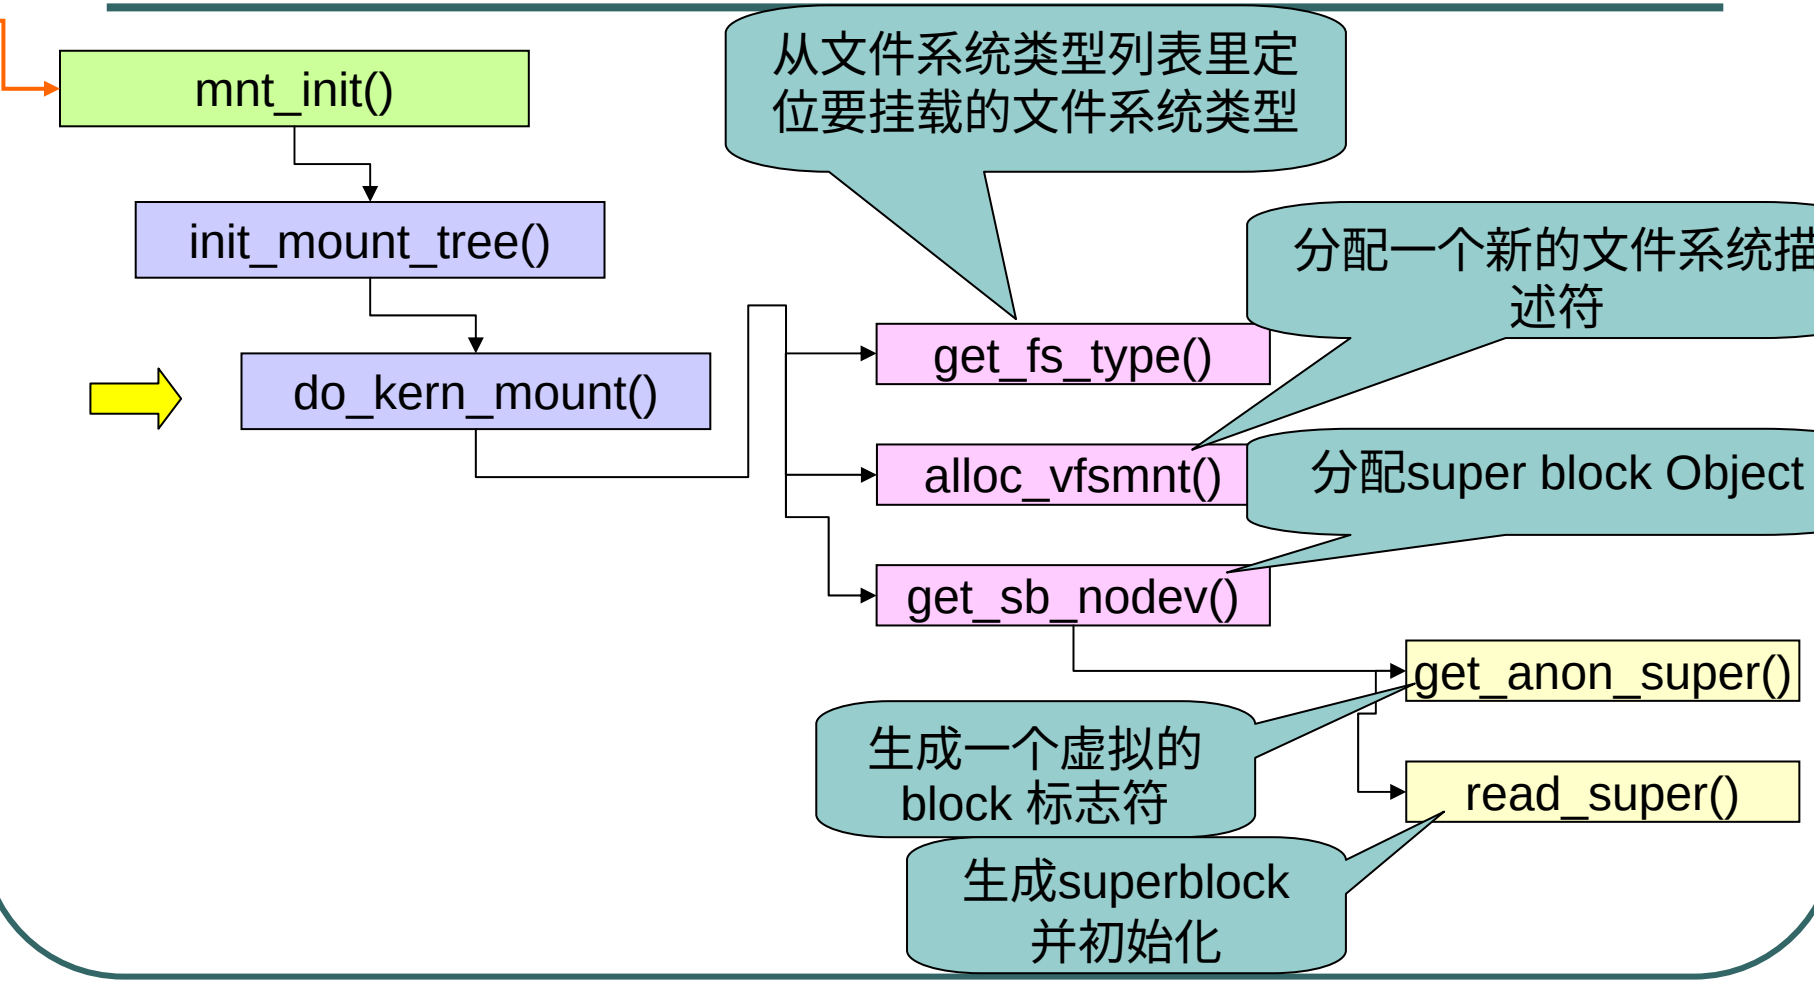

文件系统操作mount root filesystem 第二阶段-1

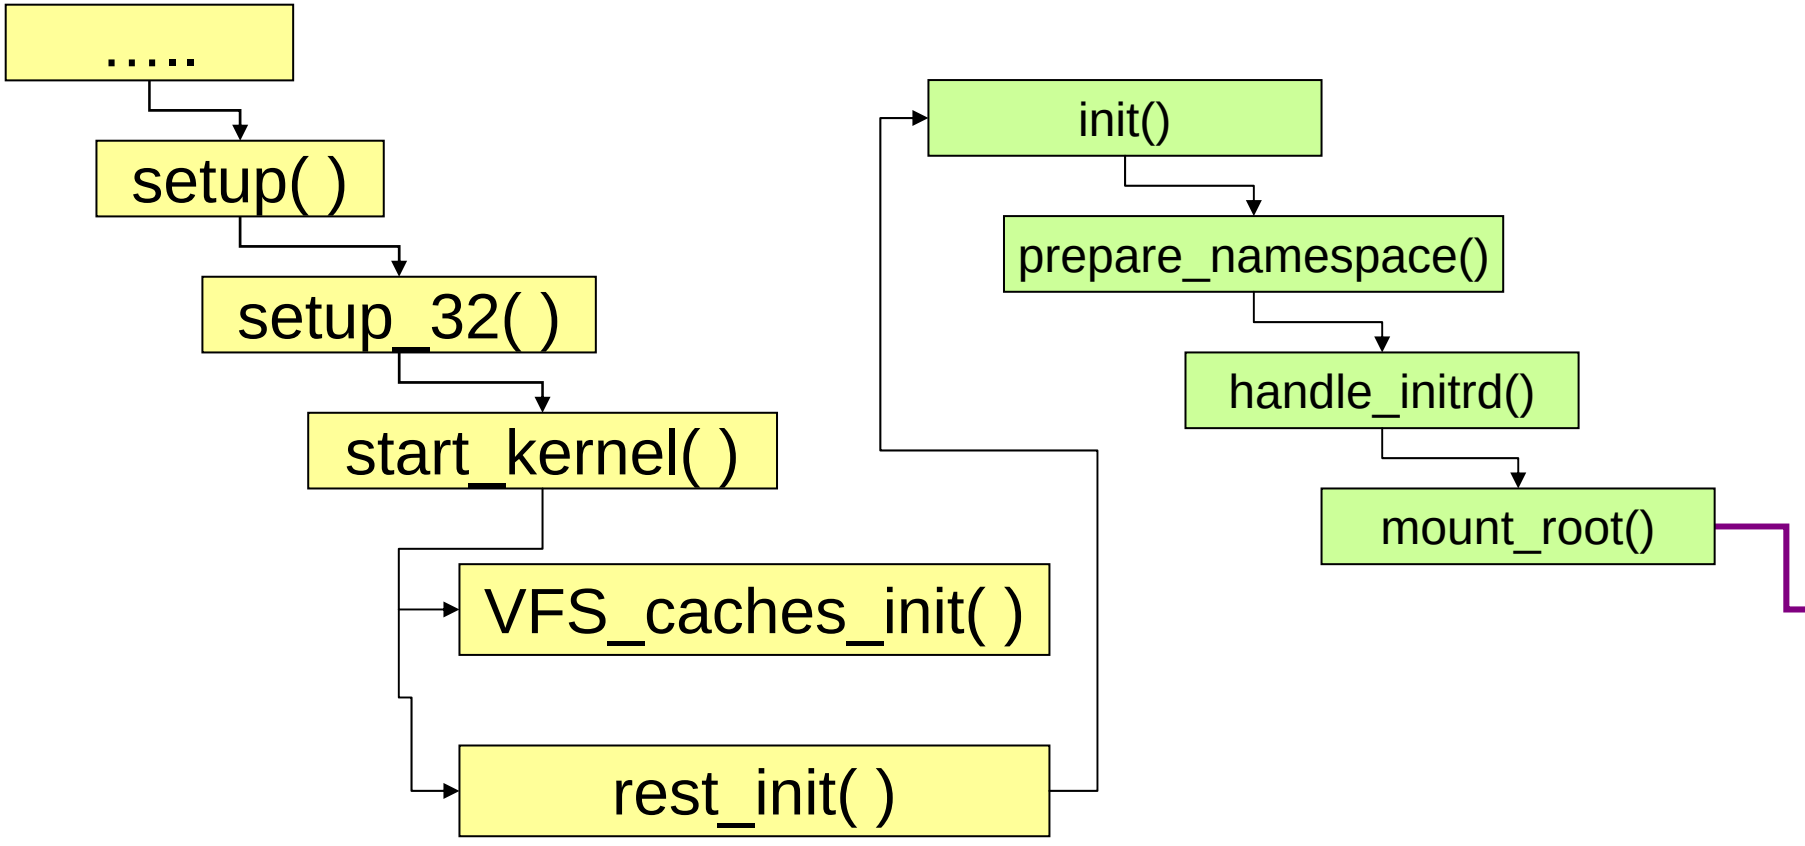

文件系统操作mount root filesystem 第二阶段-2

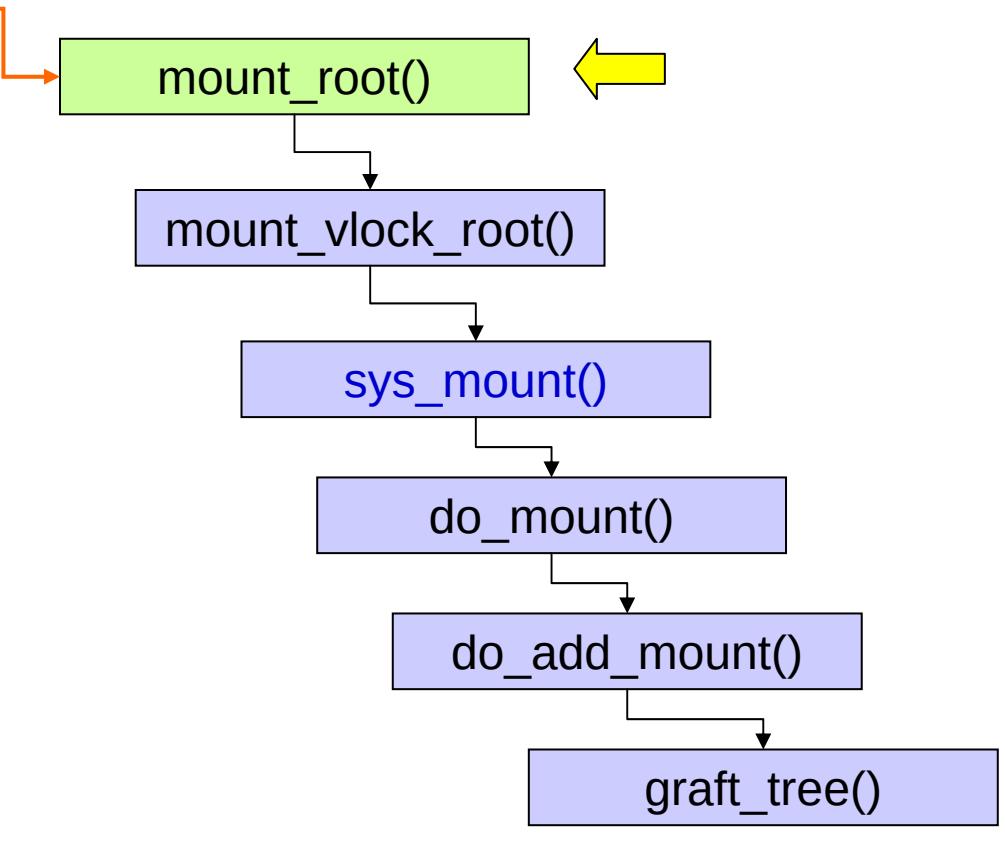

参考文献

- Remy Card, Theodore Ts'o, Stephen Tweedie, Design and Implementation of the Second Extended Filesystem
- Daniel P. Bovet, Marco Cesati，《Understanding the Linux Kernel, 2nd Edition》
- 李善平 郑扣根 《Linux操作系统及实验教程》
- 毛德操 胡希明 《Linux内核源代码情景分析》
- Linux kernel 2.4.20 源码
- www.linuxforum.net

谢谢！

敬请关注：

Linux 源码分析系列之

设备驱动

主讲：杨少华